

Instituto Federal Goiano - Campus Ceres
Bacharelado em Sistemas de Informação
Prof. Me. Ronneesley Moura Teles

Adallberto Lucena Moura
Andrey Silva Ribeiro
Anny Karoliny Moraes Ribeiro
Brenner Gomes de Jesus
Davi Ildeu de Faria
Eduardo de Oliveira Silva
Gleyson Israel Alves
Gusttavo Nunes Gomes
Ianka Talita Bastos de Assis
Ígor Justino Rodrigues

Algoritmo Viola-Jones

Sumário

1	Viola - Jones	2
2	Funcionamento do algoritmo	3
2.1	Integral Image	3
2.2	Haar Feature	3
2.3	AdaBoost	4
3	Vantagem	4
4	Desvantagem	4
5	Implementação Viola-Jones em Python	4
5.1	Por quê a implementação em Python?	4
5.2	IntegralImage.py	5
5.3	HaarLikeFeature.py	6
5.4	AdaBoost.py	8
5.5	Utils.py	10
6	Referências Bibliográfica	13

Algoritmo Viola-Jones

1 Viola - Jones

O método *Viola-Jones* proposto por *Paul Viola* e *Michael Jones* em 2001, é um algoritmo utilizado em diversas áreas da tecnologia, uma delas é a detecção de faces. Paul e Michael eram pesquisadores de Cambridge onde optaram por explorar o lado radical da programação, sendo assim, publicaram um artigo intitulado: “*Rapid Object Detection using a Boosted Cascade of Simple Features*” que demonstrou uma nova forma de detectar faces. O artigo bem como o conceito Viola-Jones faz uso de 3 abordagens diferenciadas, pautando pontos considerados de extrema importância, sendo eles: as características de *Haar*, o algoritmo de aprendizado *AdaBoost* e os classificadores em Cascata.

As características de Haar proposta pelo matemático húngaro Alfred Haar em 1909, foi a primeira maneira considerada nova de representar uma “*imagem integral*” (*Integral Image*, em inglês), que permitiu os detectores utilizados por eles, computarem as imagens de forma rápida e eficaz. *Haar* é uma característica intitulada como transformada onde varia da matemática discreta que faz uso em diversos processos de análises de sinais, em meios de compressão de dados e amplas outras aplicações no ramo de engenharia e ciência da computação.

A segunda abordagem essencial foi o algoritmo de aprendizado baseado em *AdaBoost*. O algoritmo *AdaBoost* é caracterizado por algoritmo de *Machine Learning* (aprendizado de máquina, em português) inventado por Yoav Freund e Robert Schapire, o algoritmo meta-heurístico é usado para aumentar significativamente a performance dos algoritmos de aprendizagem. *AdaBoost* é derivado do nome *Adaptive Boosting* (impulso adaptativo, significado em português) algoritmo colocado como ajustável a diversas circunstâncias e adaptável para classificações subsequentes. O algoritmo seleciona um número pequeno de características visuais críticas de um conjunto maior e com seus classificadores torna-se extremamente eficiente.

Tendo em vista tais ferramentas úteis para elaboração do algoritmo, Paul e Michael implementaram os classificadores em Cascata. Os classificadores são responsáveis por selecionar criteriosamente um determinado objeto, levando em consideração a concomitância de suas principais características. As características necessárias para utilização são encontradas a partir de amplos algoritmos de aprendizado como *Support Vector Machine*, redes neurais, entre outros. Os classificadores em cascata possuem como principal função combinar e incrementar métodos que tendenciam melhorar a perspectiva do objeto, ou seja, permitiam com que diversas regiões do fundo da foto fossem rapidamente destacadas disponibilizando maior processamento computacional.

Por conseguinte, rejeitavam um largo número de regiões que demonstravam ter o aspecto escolhido tornando-o então, cada vez mais prudente para que não ocorresse casos de falsos objetos nas análises dos mesmos. Os autores aprofundaram seus métodos de acordo com a construção do algoritmo, deste modo, realizaram comparações em relação a diferentes algoritmos similares da época, bem como, *Rowley-Baluja-Kanade*, *Schneiderman-Kanade* e *Roth-Yang-Ahuja* para que pudessem encontrar meios de solucionar a forma como funcionavam as equações e obter assim, resultados satisfatórios.

O algoritmo Viola-Jones é uma variação do *AdaBoost*, algoritmo de aprendizado. Porém, por ser uma alternância, o algoritmo Viola-Jones é bastante utilizado. Devido

sua implementação seguir uma abordagem diferente para construir um novo sistema de detecção, ele consegue alcançar aproximadamente 15 vezes mais rápido que os métodos anteriores. Viola-Jones é perfeitamente apto a detectar faces com maior precisão usando *Haar* como uma das implementações, é notório a perspectiva que há em aplicar o algoritmo em diversas situações. O método Viola-Jones revolucionou o campo da computação tornando-se referência para os demais.

2 Funcionamento do algoritmo

2.1 Integral Image




Figura 1: Integral Image

2.2 Haar Feature




Figura 2: Haar




Figura 3: Classificadores em Cascata

2.3 AdaBoost

3 Vantagem

- 15 vezes mais rápido que o algoritmo “*Rowley-Baluja-Kanade*” no processamento da imagem.
- 600 vezes se comparado ao “*Schneiderman-Kanade*”.

4 Desvantagem

- A detecção de faces só é possível se o rosto estiver na posição frontal.
- A base de dados usada precisa de faces em diferentes condições, sendo elas: iluminação, brilho, escala, pose e variações de câmera.
- Nível de detecção na literatura - 80% (FAUX,2012);
- É um algoritmo de detecção de face não de reconhecimento facial.

5 Implementação Viola-Jones em Python

5.1 Por quê a implementação em Python?

Existem inúmeras implementações do algoritmo disponíveis em plataformas confiáveis para utilização. Diversas linguagens foram desenvolvidas sendo elas as mais comuns em *MatLab*, *Java* e *Python*. A implementação em *MatLab* não é de extrema importância devido a ferramenta em si, não descartando sua utilização e benefícios para desenvolver procedimentos como o de detecção facial. Porém, é uma ferramenta paga e um projeto que demanda uma alta porcentagem de acertos e usabilidade, onde a interação de muitos indivíduos seriam colocados em pauta, viria deixar de ser uma solução para então tornar-se um problema se o usuário não obtiver a licença de uso, ou seja, dificultaria o processo e por delonga foi devidamente descartado.

Java era bastante abundante no *GitHub*, entretanto a maioria estava incompleta ou não possuía os códigos necessários para o treinamento da rede, o que faz-se importante para o sucesso do algoritmo e para que tenham uma base de dados ampla gerando uma maior eficiência na detecção de imagens. Os códigos que estavam aparentemente completos deixava a desejar a documentação estando assim incoerente ou inexistente o que por sua vez, dificultou a utilização do mesmo, sendo mais vantajoso optar por uma ampliação do que gastar tempo em códigos alheios.

Deste modo, escolhemos a implementação de *Simon Hohberg* com o algoritmo em Python, que por conseguinte, estava disponível no *Github* pessoal do desenvolvedor: <https://github.com/Simon-Hohberg/Viola-Jones>. *Python* é considerada uma linguagem simples, mas nem por isso menos robusta. Nota-se que é amplamente utilizada em processos de *Machine Learning* (aprendizado de máquina, em português) e a implementação encontrada está com todas as partes do algoritmo, desde a detecção até o treinamento, sendo assim, a documentação do código bem-feita e planejada, o que possibilitaria o uso.

5.2 IntegralImage.py

```
1 import numpy as np
2
3
4 """
5 In an integral image each pixel is the sum of all pixels in the
6 original image
7 that are 'left and above' the pixel.
8
9 Original      Integral
10 +-----+    +-----+
11 | 1 2 3 . |    | 0 0 0 0 . |
12 | 4 5 6 . |    | 0 1 3 6 . |
13 | . . . . |    | 0 5 12 21 . |
14 |         |    | . . . . . |
15 """
16
17
18 def to_integral_image(img_arr):
19     """
20     Calculates the integral image based on this instance's original
21     image data.
22     :param img_arr: Image source data
23     :type img_arr: numpy.ndarray
24     :return Integral image for given image
25     :rtype: numpy.ndarray
26     """
27     # an index of -1 refers to the last row/column
28     # since row_sum is calculated starting from (0,0),
29     # rowSum(x, -1) == 0 holds for all x
30     row_sum = np.zeros(img_arr.shape)
31     # we need an additional column and row
32     integral_image_arr = np.zeros((img_arr.shape[0] + 1, img_arr.shape
33     [1] + 1))
34     for x in range(img_arr.shape[1]):
35         for y in range(img_arr.shape[0]):
36             row_sum[y, x] = row_sum[y-1, x] + img_arr[y, x]
37             integral_image_arr[y+1, x+1] = integral_image_arr[y+1, x
38             -1+1] + row_sum[y, x]
39     return integral_image_arr
40
41
42 def sum_region(integral_img_arr, top_left, bottom_right):
43     """
44     Calculates the sum in the rectangle specified by the given tuples.
45     :param integral_img_arr:
46     :type integral_img_arr: numpy.ndarray
47     :param top_left: (x, y) of the rectangle's top left corner
48     :type top_left: (int, int)
49     :param bottom_right: (x, y) of the rectangle's bottom right corner
50     :type bottom_right: (int, int)
51     :return The sum of all pixels in the given rectangle
52     :rtype int
53     """
54     # swap tuples
55     top_left = (top_left[1], top_left[0])
56     bottom_right = (bottom_right[1], bottom_right[0])
57     if top_left == bottom_right:
```

```

55         return integral_img_arr[top_left]
56     top_right = (bottom_right[0], top_left[1])
57     bottom_left = (top_left[0], bottom_right[1])
58     return integral_img_arr[bottom_right] - integral_img_arr[top_right]
    - integral_img_arr[bottom_left] + integral_img_arr[top_left]

```

recursos/codigo-python/Viola-Jones-master/violajones/IntegralImage.py

5.3 HaarLikeFeature.py

```

1 import violajones.IntegralImage as ii
2
3
4 def enum(**enums):
5     return type('Enum', (), enums)
6
7 FeatureType = enum(TWO_VERTICAL=(1, 2), TWO_HORIZONTAL=(2, 1),
8     THREE_HORIZONTAL=(3, 1), THREE_VERTICAL=(1, 3), FOUR=(2, 2))
9 FeatureTypes = [FeatureType.TWO_VERTICAL, FeatureType.TWO_HORIZONTAL,
10     FeatureType.THREE_VERTICAL, FeatureType.THREE_HORIZONTAL,
11     FeatureType.FOUR]
12
13 class HaarLikeFeature(object):
14     """
15     Class representing a haar-like feature.
16     """
17
18     def __init__(self, feature_type, position, width, height, threshold,
19         polarity):
20         """
21         Creates a new haar-like feature.
22         :param feature_type: Type of new feature, see FeatureType enum
23         :type feature_type: violajonse.HaarLikeFeature.FeatureTypes
24         :param position: Top left corner where the feature begins (x, y)
25         :type position: (int, int)
26         :param width: Width of the feature
27         :type width: int
28         :param height: Height of the feature
29         :type height: int
30         :param threshold: Feature threshold
31         :type threshold: float
32         :param polarity: polarity of the feature -1 or 1
33         :type polarity: int
34         """
35         self.type = feature_type
36         self.top_left = position
37         self.bottom_right = (position[0] + width, position[1] + height)
38         self.width = width
39         self.height = height
40         self.threshold = threshold
41         self.polarity = polarity
42         self.weight = 1
43
44     def get_score(self, int_img):
45         """
46         Get score for given integral image array.
47         :param int_img: Integral image array

```

```

45         :type int_img: numpy.ndarray
46         :return: Score for given feature
47         :rtype: float
48         """
49         score = 0
50         if self.type == FeatureType.TWO_VERTICAL:
51             first = ii.sum_region(int_img, self.top_left, (self.
top_left[0] + self.width, int(self.top_left[1] + self.height / 2)))
52             second = ii.sum_region(int_img, (self.top_left[0], int(self
.top_left[1] + self.height / 2)), self.bottom_right)
53             score = first - second
54         elif self.type == FeatureType.TWO_HORIZONTAL:
55             first = ii.sum_region(int_img, self.top_left, (int(self.
top_left[0] + self.width / 2), self.top_left[1] + self.height))
56             second = ii.sum_region(int_img, (int(self.top_left[0] +
self.width / 2), self.top_left[1]), self.bottom_right)
57             score = first - second
58         elif self.type == FeatureType.THREE_HORIZONTAL:
59             first = ii.sum_region(int_img, self.top_left, (int(self.
top_left[0] + self.width / 3), self.top_left[1] + self.height))
60             second = ii.sum_region(int_img, (int(self.top_left[0] +
self.width / 3), self.top_left[1]), (int(self.top_left[0] + 2 *
self.width / 3), self.top_left[1] + self.height))
61             third = ii.sum_region(int_img, (int(self.top_left[0] + 2 *
self.width / 3), self.top_left[1]), self.bottom_right)
62             score = first - second + third
63         elif self.type == FeatureType.THREE_VERTICAL:
64             first = ii.sum_region(int_img, self.top_left, (self.
bottom_right[0], int(self.top_left[1] + self.height / 3)))
65             second = ii.sum_region(int_img, (self.top_left[0], int(self
.top_left[1] + self.height / 3)), (self.bottom_right[0], int(self.
top_left[1] + 2 * self.height / 3)))
66             third = ii.sum_region(int_img, (self.top_left[0], int(self.
top_left[1] + 2 * self.height / 3)), self.bottom_right)
67             score = first - second + third
68         elif self.type == FeatureType.FOUR:
69             # top left area
70             first = ii.sum_region(int_img, self.top_left, (int(self.
top_left[0] + self.width / 2), int(self.top_left[1] + self.height /
2)))
71             # top right area
72             second = ii.sum_region(int_img, (int(self.top_left[0] +
self.width / 2), self.top_left[1]), (self.bottom_right[0], int(self
.top_left[1] + self.height / 2)))
73             # bottom left area
74             third = ii.sum_region(int_img, (self.top_left[0], int(self.
top_left[1] + self.height / 2)), (int(self.top_left[0] + self.width
/ 2), self.bottom_right[1]))
75             # bottom right area
76             fourth = ii.sum_region(int_img, (int(self.top_left[0] +
self.width / 2), int(self.top_left[1] + self.height / 2)), self.
bottom_right)
77             score = first - second - third + fourth
78         return score
79
80     def get_vote(self, int_img):
81         """
82         Get vote of this feature for given integral image.
83         :param int_img: Integral image array
84         :type int_img: numpy.ndarray

```



```

85         :return: 1 iff this feature votes positively , otherwise -1
86         :rtype: int
87         """
88         score = self.get_score(int_img)
89         return self.weight * (1 if score < self.polarity * self.
threshold else -1)

```

recursos/codigo-python/Viola-Jones-master/violaJones/HaarLikeFeature.py

5.4 AdaBoost.py

```

1 from functools import partial
2 import numpy as np
3 from violajones.HaarLikeFeature import HaarLikeFeature
4 from violajones.HaarLikeFeature import FeatureTypes
5 import progressbar
6 from multiprocessing import Pool
7
8 LOADING_BAR_LENGTH = 50
9
10
11 # TODO: select optimal threshold for each feature
12 # TODO: attentional cascading
13
14 def learn(positive_iis , negative_iis , num_classifiers=-1,
min_feature_width=1, max_feature_width=-1, min_feature_height=1,
max_feature_height=-1):
15     """
16     Selects a set of classifiers. Iteratively takes the best
17     classifiers based
18     on a weighted error.
19     :param positive_iis: List of positive integral image examples
20     :type positive_iis: list[numpy.ndarray]
21     :param negative_iis: List of negative integral image examples
22     :type negative_iis: list[numpy.ndarray]
23     :param num_classifiers: Number of classifiers to select , -1 will
24     use all
25     classifiers
26     :type num_classifiers: int
27
28     :return: List of selected features
29     :rtype: list[violajones.HaarLikeFeature.HaarLikeFeature]
30     """
31     num_pos = len(positive_iis)
32     num_neg = len(negative_iis)
33     num_imgs = num_pos + num_neg
34     img_height , img_width = positive_iis[0].shape
35
36     # Maximum feature width and height default to image width and
37     height
38     max_feature_height = img_height if max_feature_height == -1 else
39     max_feature_height
40     max_feature_width = img_width if max_feature_width == -1 else
41     max_feature_width
42
43     # Create initial weights and labels
44     pos_weights = np.ones(num_pos) * 1. / (2 * num_pos)
45     neg_weights = np.ones(num_neg) * 1. / (2 * num_neg)
46     weights = np.hstack((pos_weights , neg_weights))

```

```

42 labels = np.hstack((np.ones(num_pos), np.ones(num_neg) * -1))
43
44 images = positive_iis + negative_iis
45
46 # Create features for all sizes and locations
47 features = _create_features(img_height, img_width,
48 min_feature_width, max_feature_width, min_feature_height,
49 max_feature_height)
50 num_features = len(features)
51 feature_indexes = list(range(num_features))
52
53 num_classifiers = num_features if num_classifiers == -1 else
54 num_classifiers
55
56 print('Calculating scores for images..')
57
58 votes = np.zeros((num_imgs, num_features))
59 bar = progressbar.ProgressBar()
60 # Use as many workers as there are CPUs
61 pool = Pool(processes=None)
62 for i in bar(range(num_imgs)):
63     votes[i, :] = np.array(list(pool.map(partial(_get_feature_vote,
64 image=images[i]), features)))
65
66 # select classifiers
67
68 classifiers = []
69
70 print('Selecting classifiers..')
71 bar = progressbar.ProgressBar()
72 for _ in bar(range(num_classifiers)):
73
74     classification_errors = np.zeros(len(feature_indexes))
75
76     # normalize weights
77     weights *= 1. / np.sum(weights)
78
79     # select best classifier based on the weighted error
80     for f in range(len(feature_indexes)):
81         f_idx = feature_indexes[f]
82         # classifier error is the sum of image weights where the
83         classifier
84         # is right
85         error = sum(map(lambda img_idx: weights[img_idx] if labels[
86 img_idx] != votes[img_idx, f_idx] else 0, range(num_imgs)))
87         classification_errors[f] = error
88
89     # get best feature, i.e. with smallest error
90     min_error_idx = np.argmin(classification_errors)
91     best_error = classification_errors[min_error_idx]
92     best_feature_idx = feature_indexes[min_error_idx]
93
94     # set feature weight
95     best_feature = features[best_feature_idx]
96     feature_weight = 0.5 * np.log((1 - best_error) / best_error)
97     best_feature.weight = feature_weight
98
99     classifiers.append(best_feature)
100
101 # update image weights

```

```

96         weights = np.array(list(map(lambda img_idx: weights[img_idx] *
np.sqrt((1-best_error)/best_error) if labels[img_idx] != votes[
img_idx, best_feature_idx] else weights[img_idx] * np.sqrt(
best_error/(1-best_error)), range(num_imgs))))
97
98         # remove feature (a feature can't be selected twice)
99         feature_indexes.remove(best_feature_idx)
100
101     return classifiers
102
103
104 def _get_feature_vote(feature, image):
105     return feature.get_vote(image)
106
107
108 def _create_features(img_height, img_width, min_feature_width,
max_feature_width, min_feature_height, max_feature_height):
109     print('Creating haar-like features..')
110     features = []
111     for feature in FeatureTypes:
112         # FeatureTypes are just tuples
113         feature_start_width = max(min_feature_width, feature[0])
114         for feature_width in range(feature_start_width,
max_feature_width, feature[0]):
115             feature_start_height = max(min_feature_height, feature[1])
116             for feature_height in range(feature_start_height,
max_feature_height, feature[1]):
117                 for x in range(img_width - feature_width):
118                     for y in range(img_height - feature_height):
119                         features.append(HaarLikeFeature(feature, (x, y)
, feature_width, feature_height, 0, 1))
120                         features.append(HaarLikeFeature(feature, (x, y)
, feature_width, feature_height, 0, -1))
121     print('..done. ' + str(len(features)) + ' features created.\n')
122     return features

```

recursos/codigo-python/Viola-Jones-master/viola-jones/AdaBoost.py

5.5 Utils.py

```

1 import numpy as np
2 from PIL import Image
3 from violajones.HaarLikeFeature import FeatureType
4 from functools import partial
5 import os
6
7
8 def ensemble_vote(int_img, classifiers):
9     """
10     Classifies given integral image (numpy array) using given
11     classifiers, i.e.
12     if the sum of all classifier votes is greater 0, image is
13     classified
14     positively (1) else negatively (0). The threshold is 0, because
15     votes can be
16     +1 or -1.
17     :param int_img: Integral image to be classified
18     :type int_img: numpy.ndarray
19     :param classifiers: List of classifiers

```

```

17 :type classifiers: list[violajones.HaarLikeFeature.HaarLikeFeature]
18 :return: 1 iff sum of classifier votes is greater 0, else 0
19 :rtype: int
20 """
21 return 1 if sum([c.get_vote(int_img) for c in classifiers]) >= 0
   else 0
22
23
24 def ensemble_vote_all(int_imgs, classifiers):
25     """
26     Classifies given list of integral images (numpy arrays) using
27     classifiers,
28     i.e. if the sum of all classifier votes is greater 0, an image is
29     classified
30     positively (1) else negatively (0). The threshold is 0, because
31     votes can be
32     +1 or -1.
33     :param int_imgs: List of integral images to be classified
34     :type int_imgs: list[numpy.ndarray]
35     :param classifiers: List of classifiers
36     :type classifiers: list[violajones.HaarLikeFeature.HaarLikeFeature]
37     :return: List of assigned labels, 1 if image was classified
38     positively, else
39     0
40     :rtype: list[int]
41     """
42     vote_partial = partial(ensemble_vote, classifiers=classifiers)
43     return list(map(vote_partial, int_imgs))
44
45
46 def reconstruct(classifiers, img_size):
47     """
48     Creates an image by putting all given classifiers on top of each
49     other
50     producing an archetype of the learned class of object.
51     :param classifiers: List of classifiers
52     :type classifiers: list[violajones.HaarLikeFeature.HaarLikeFeature]
53     :param img_size: Tuple of width and height
54     :type img_size: (int, int)
55     :return: Reconstructed image
56     :rtype: PIL.Image
57     """
58     image = np.zeros(img_size)
59     for c in classifiers:
60         # map polarity: -1 -> 0, 1 -> 1
61         polarity = pow(1 + c.polarity, 2)/4
62         if c.type == FeatureType.TWO_VERTICAL:
63             for x in range(c.width):
64                 sign = polarity
65                 for y in range(c.height):
66                     if y >= c.height/2:
67                         sign = (sign + 1) % 2
68                     image[c.top_left[1] + y, c.top_left[0] + x] += 1 *
69             sign * c.weight
67         elif c.type == FeatureType.TWO_HORIZONTAL:
68             sign = polarity
69             for x in range(c.width):
70                 if x >= c.width/2:
71                     sign = (sign + 1) % 2
72                 for y in range(c.height):

```

```

70         image[c.top_left[0] + x, c.top_left[1] + y] += 1 *
sign * c.weight
71     elif c.type == FeatureType.THREE.HORIZONTAL:
72         sign = polarity
73         for x in range(c.width):
74             if x % c.width/3 == 0:
75                 sign = (sign + 1) % 2
76             for y in range(c.height):
77                 image[c.top_left[0] + x, c.top_left[1] + y] += 1 *
sign * c.weight
78     elif c.type == FeatureType.THREE.VERTICAL:
79         for x in range(c.width):
80             sign = polarity
81             for y in range(c.height):
82                 if x % c.height/3 == 0:
83                     sign = (sign + 1) % 2
84                 image[c.top_left[0] + x, c.top_left[1] + y] += 1 *
sign * c.weight
85     elif c.type == FeatureType.FOUR:
86         sign = polarity
87         for x in range(c.width):
88             if x % c.width/2 == 0:
89                 sign = (sign + 1) % 2
90             for y in range(c.height):
91                 if x % c.height/2 == 0:
92                     sign = (sign + 1) % 2
93                 image[c.top_left[0] + x, c.top_left[1] + y] += 1 *
sign * c.weight
94     image -= image.min()
95     image /= image.max()
96     image *= 255
97     result = Image.fromarray(image.astype(np.uint8))
98     return result
99
100
101 def load_images(path):
102     images = []
103     for _file in os.listdir(path):
104         if _file.endswith('.png'):
105             img_arr = np.array(Image.open((os.path.join(path, _file))),
dtype=np.float64)
106             img_arr /= img_arr.max()
107             images.append(img_arr)
108     return images

```

recursos/codigo_python/Viola-Jones-master/violajones/Utils.py

6 Referências Bibliográfica

VIOLA, Paul; JONES, Michael. **Rapid object detection using a boosted cascade of simple features**. Proceedings of the 2001 IEEE Computer Society Conference on Computer Vision and Pattern Recognition. CVPR 2001, v. 1, p. I-511-I-518, 2001. Disponível em: <<http://ieeexplore.ieee.org/document/990517/>>.

VIOLA, Paul; JONES, Michael. **Robust Real-Time Face Detection** International Journal of Computer Vision 57(2), 137–154, 2004.

CHAVES, Bruno Butilhão. **Estudo do algoritmo AdaBoost de aprendizagem de máquina aplicado a sensores e sistemas embarcados**. 2011. Dissertação (Mestrado em Engenharia de Controle e Automação Mecânica) - Escola Politécnica, Universidade de São Paulo, São Paulo, 2011. doi:10.11606/D.3.2011.tde-12062012-163740. Acesso em: 2017-10-11..

IRGENS, Peter et al. **An efficient and cost effective FPGA based implementation of the Viola-Jones face detection algorithm**. HardwareX, v. 1, p. 68–75, 2017. Disponível em: <<http://linkinghub.elsevier.com/retrieve/pii/S2468067216300116>>.

SANTOS, Ligneul. **Detecção de faces através do algoritmo de Viola-Jones**. Coppe/Ufrj, 2011.

FAUX, Francis e LUTHON, Franck. **Theory of evidence for face detection and tracking**. International Journal of Approximate Reasoning, v. 53, n. 5, p. 728–746, 2012. Disponível em: <<http://dx.doi.org/10.1016/j.ijar.2012.02.002>>.

BODHI, S. R. e NAVEEN, S. **Face detection, registration and feature localization experiments with RGB-D face database**. Procedia Computer Science, v. 46, n. Ict 2014, p. 1778–1785, 2015. Disponível em: <<http://dx.doi.org/10.1016/j.procs.2015.02.132>>.